SpacerScope 用户手册（中文版）

1. 简介

什么是 SpacerScope?

SpacerScope 是一款面向 **CRISPR/Cas 基因组编辑**应用的高效脱靶分析工具，旨在解决大规模参考基因组，尤其是复杂植物基因组场景下传统方法计算开销高、响应慢、难以兼顾速度与精度的问题。

SpacerScope 的核心思想是将脱靶搜索拆分为**位点提取、快速预筛和精确验证**三个阶段。程序首先从查询序列和参考基因组中提取满足 PAM 约束的候选 spacer 位点；随后针对不同搜索任务采用不同的高效编码策略：在**错配搜索**中，使用紧凑的 **2-bit 序列编码**与批量化扫描策略进行快速汉明距离判断；在**插入/缺失搜索**中，先将序列编码为多通道二进制特征，利用**通道过滤与批量掩码融合**大幅压缩候选集合，再对保留下来的少量候选执行精确比对。对于 indel 验证，SpacerScope 采用的是**右端锚定的编辑距离动态规划**，而不是简单的局部比对，从而更适合 CRISPR spacer 场景下插入、缺失与末端约束共存的序列比较需求。

因此，SpacerScope 并不是单纯依赖传统全序列比对，而是通过**二进制编码驱动的高效预过滤**与**精确编辑距离验证**相结合，在保证结果完整性和准确性的前提下，显著降低整体搜索成本。实际测试表明，SpacerScope 能够在复杂基因组背景下实现快速、稳定且高精度的 gRNA 筛选与脱靶分析。

SpacerScope的核心特点

1. **完美的脱靶检出能力**
   在给定 PAM、错配数和 indel 数等约束条件下，SpacerScope 能够对满足条件的候选位点进行系统性搜索，并在精确验证阶段尽可能保证结果完整性与判定准确性。
2. **同时支持错配与 indel 脱靶分析**
   SpacerScope 不仅支持常规的**碱基替换（mismatch）**检测，还支持**插入（insertion）**与**缺失（deletion）**的脱靶识别，能够覆盖更常见也更复杂的 CRISPR/Cas 潜在脱靶类型。
3. **高效的二进制编码与预过滤机制**
   程序针对不同任务采用专门设计的二进制表示与预筛策略：
   - 在错配搜索中，使用紧凑的 **2-bit 编码**和批量扫描加速大规模汉明距离计算；
   - 在 indel 搜索中，使用多通道编码、二进制过滤和批量掩码融合显著降低需要进入精确比对的候选规模。这种“先快速过滤、后精确验证”的设计显著提升了整体运行效率。
4. **适用于大规模基因组分析**
   通过针对内存访问、并行调度和候选筛选流程的优化，SpacerScope 能够在较大的参考基因组上保持较好的计算效率，尤其适合复杂植物基因组等高负载场景。

5. **多模式输入与分析流程**
   SpacerScope 同时支持：
   - 直接输入 FASTA 查询序列；
   - 基于注释文件提取目标序列进行分析；
   - 常规模式与低内存 cut 模式。
     其中 cut 模式可在内存资源有限的设备上按染色体流式处理参考基因组。
6. **跨平台兼容**
   提供 **Windows**、**Linux**和**Mac** 平台支持，既可作为命令行工具运行，也可通过 spacerscope-web 以浏览器方式使用。由于Mac系统的特殊性，用户需要自行编译打包。
7. **并行与底层优化支持**
   程序支持多线程并行执行，并可在支持的硬件与编译环境下利用 **AVX2 / SSE4.1** 等指令优化，以进一步提升实际运行性能。
8. **适配多种 CRISPR 系统**
   支持用户自定义 **PAM 序列**及其相对方向，可适配不同核酸酶系统和不同实验设计需求。

---

2. 程序组成

当前版本发布时通常包含两个可执行文件：

- `spacerscope`：主程序
- `spacerscope-web`：Web 图形壳，内部通过子进程调用 `spacerscope`

两者关系如下：

- `spacerscope` 负责所有实际计算，可单独运行。
- `spacerscope-web` 通过浏览器实现GUI，也方便网络访问。spacerscope-web 不是独立搜索引擎，必须与 `spacerscope` 搭配使用

---

3. 环境要求

支持的操作系统

- Windows x64
- Linux x86_64
- Mac

CPU 指令集

推荐 CPU 支持：

- AVX2
- SSE4.1

Linux 可参考此命令查阅是否支持：

```
lscpu | grep -E 'avx2|sse4_1' | sed 's/^[[:space:]]*//'
```

程序即使在不支持 AVX2 的机器上也可运行，但性能可能下降。

运行依赖

核心依赖为：

- OpenMP
- zlib

如使用 `spacerscope-web`，无需额外安装浏览器以外的软件；只需保证同目录或指定路径下能找到 `spacerscope` 主程序。

---

4. 运行模式

SpacerScope 当前支持 4 种主模式：

模式	输入方式	内存策略	说明
`fasta`	查询 FASTA + 参考 FASTA	常规模式	直接使用 FASTA 查询序列
`fasta-cut`	查询 FASTA + 参考 FASTA	低内存模式	按染色体流式处理参考序列
`anno`	注释文件 + gene ID + 参考 FASTA	常规模式	从注释提取查询序列后运行
`anno-cut`	注释文件 + gene ID + 参考 FASTA	低内存模式	注释提取 + 按染色体低内存处理

普通模式与 cut 模式的区别

- **普通模式**：整份参考基因组加载进内存，速度通常更高。
- **cut 模式**：参考基因组按染色体逐条处理，峰值内存更低，更适合内存受限机器。

内存峰值估算

程序启动时会自动根据参考 FASTA 估算峰值内存，并要求用户确认；如需跳过，可使用：

```
-y
```

或

```
--yes
```

或

```
--skip-memory-check
```

- 普通模式峰值主要与**总基因组大小**相关

- cut 模式峰值主要与**最长染色体大小**相关

---

5. 命令行主程序：`spacerscope`

通用用法

```
spacerscope fasta <options>
spacerscope fasta-cut <options>
spacerscope anno <options>
spacerscope anno-cut <options>
spacerscope --report-tsv <file> --html-output <file>
```

查看帮助：

```
spacerscope --help
spacerscope help fasta
spacerscope help anno
```

查看版本：

```
spacerscope --version
```

通用参数

参数	说明	默认值
`-R, --ref <file>`	参考基因组 FASTA 文件	必填
`-o, --output <file>`	输出 TSV 文件	必填
`--pam <string>`	主 PAM 序列	`NGG`
`--alt-pam <string>`	备用 PAM 序列	`NAG`
`--spacer-len <int>`	spacer 长度	`20`
`--direction <up|down>`	spacer 相对于 PAM 的方向	`up`
`-m, --mismatch <int>`	最大错配数	`4`
`-i, --indel <int>`	最大 indel 数	`2`
`--dust-threshold <int>`	DUST 低复杂度过滤阈值	`12`
`-t, --threads <int>`	线程数	逻辑核心数
`-y, --yes`	跳过启动前内存确认	关闭
`--skip-memory-check`	跳过启动前内存确认	关闭
`--raw-output`	输出 7 列未评分 TSV	关闭

参数	说明	默认值
`--progress-format <text|jsonl>`	进度输出格式	`text`
`--html <0|1>`	是否生成 `<output>.html`	`1`
`-ht <0|1>`	`--html` 的别名	`1`
`--html-output <file>`	指定 HTML 输出文件	空
`--report-tsv <file>`	对已有 scored TSV 单独生成 HTML	空

`fasta / fasta-cut` 模式参数

参数	说明
`-I, --query <file>`	查询 FASTA 文件

示例

```
spacerscope fasta --query q.fa --ref ref.fa -o out.tsv
```

```
spacerscope fasta-cut --query q.fa --ref ref.fa -o out.tsv --yes
```

`anno / anno-cut` 模式参数

参数	说明
`-A, --annotation <file>`	注释文件（GFF/GFF3）
`--geneID <id>`	注释文件中的**精确 gene ID**
`--seq-type <gene|mrna|cds>`	要提取的序列层级，默认 `gene`

示例

```
spacerscope anno --annotation genes.gff3 --geneID gene:Gene1 --seq-type cds --ref ref.fa
-o out.tsv
```

```
spacerscope anno-cut --annotation genes.gff3 --geneID gene:Gene1 --seq-type gene --ref
ref.fa -o out.tsv --yes
```

`anno` 模式的重要限制

当前版本的 `anno / anno-cut` 已经并入 C++ 主程序，但注释兼容策略是**按旧约定发布**，不是任意 GFF3 的通用解析器。

请注意：

1. `--geneID` 必须与注释文件中的 **gene ID 完全一致**，不是自由 gene symbol。
2. `mrna/cds` 提取遵循旧约定：转录本关联依赖 `GeneX-mRNA` **命名关系**。
3. 对于通用 `Parent=transcript:...` 风格的 GFF3，当前版本 **不承诺** 在 `mrna/cds` 模式下完全兼容。

如果你的注释文件格式复杂或不统一，建议：

- 先手动提取目标基因序列
- 再使用 `fasta` 或 `fasta-cut` 模式运行

`--raw-output` 与 HTML 报告

当前版本中：

- 正常输出：**9 列 scored TSV**
- `--raw-output`：输出 **7 列未评分合并 TSV**

`--raw-output` 生成的文件列为：

列名
QueryName
QuerySeq
TargetName
TargetSeq
Distance
SearchType
GenomicFrequency

注意：

- `--raw-output` 与 `--html-output` **不能同时使用**
- HTML 报告只支持基于 scored TSV 生成

仅根据已有 TSV 生成 HTML

如果已经有 scored TSV，可单独生成 HTML：

```
spacerscope --report-tsv out.tsv --html-output out.html
```

---

6. Web 版本（GUI）：`spacerscope-web`

适用场景

`spacerscope-web` 是当前版本提供的本地网页壳，适合：

- 无桌面环境的 Linux 服务器
- 希望通过浏览器配置参数和查看结果的用户
- 通过 SSH 端口转发访问本机服务的场景

启动方式

```
spacerscope-web
```

（要求：在同路径下存在spacerscope主程序）

默认监听：

```
127.0.0.1:8787
```

常用参数：

参数	说明	默认值
`--bind <host>`	绑定地址	`127.0.0.1`
`--port <int>`	监听端口	`8787`
`--workspace-root <dir>`	Web 工作目录	系统临时目录下 `spacerscope-web`
`--spacerscope-bin <path>`	指定 `spacerscope` 主程序路径	同目录自动查找
`-h, --help`	显示帮助	-
`-v, --version`	显示版本	-

示例

```
spacerscope-web --bind 127.0.0.1 --port 8787
spacerscope-web
```

访问方式

浏览器打开：

```
http://127.0.0.1:8787
```

如果在远程 Linux 服务器上使用，推荐通过 SSH 端口转发访问：

```
ssh -L 8787:127.0.0.1:8787 user@server
```

然后在本地浏览器打开：

```
http://127.0.0.1:8787
```

Web 版本说明

Web 页面支持：

- `fasta / fasta-cut / anno / anno-cut`
- 服务器路径输入模式
- 文件上传模式
- 中英文切换
- 实时日志
- 实时进度
- TSV / HTML / stdout / stderr 下载

6.5 安全提示

当前 `spacerscope-web` v1 **无认证机制。**

因此：

- 默认只应绑定 `127.0.0.1`
- 若绑定到 `0.0.0.0` 或其他局域网地址，只应在**可信网络**中使用
- 不建议直接暴露到公网

---

7. 输出文件说明

默认主输出（scored TSV）

默认输出为 **9 列 scored TSV**：

列名	含义
`QueryName`	查询位点名称
`QuerySeq`	查询位点序列
`TargetName`	脱靶位点名称
`TargetSeq`	脱靶位点序列
`Distance`	编辑距离
`SearchType`	匹配类型：`Exact` / `Mismatch` / `Indel`

列名	含义
`GenomicFrequency`	该序列在基因组中的出现次数
`Score`	脱靶评分
`Details`	比对细节

HTML 报告

如果启用 HTML 输出，程序会额外生成：

```
<output>.html
```

或你通过 `--html-output` 指定的文件。

HTML 报告包含：

- 每个 query 的统计汇总
- 完全匹配 / 错配 / indel 的数量分布
- 详细结果表格

raw TSV

当使用 `--raw-output` 时，程序输出的是**7 列未评分 TSV**，不包含：

- `Score`
- `Details`

同时不会生成 HTML 报告。

---

8. 参数与运行建议

一般建议

- 大多数情况下，默认参数已经可用。
- 如无明确需要，不建议随意放大 `--indel`。
- 推荐先从默认参数开始，再根据需求微调。

关于 `--indel`

`--indel` 的增长会明显增加计算量。

通常建议：

- `--indel 0`：做完全匹配 + 错配
- `--indel 1~2`：常规推荐范围
- 更高的 `--indel`：仅在确有必要时尝试

关于 `--threads`

程序支持多线程，但线程数并非越大越好。实际速度会受到内存带宽、NUMA、机器架构等等的影响。

建议：

- 先用默认线程数或机器的常用高性能线程数测试
- 在服务器上实测确定最优值

8.4 关于 cut 模式

cut 模式的目标是**降低峰值内存**，不一定总是更快。内存足够时，普通模式通常更直接；内存受限时，cut 模式更安全。

---

9. 注意事项与已知限制

1. 建议使用时全部相关文件在**英文路径**下。
2. 不建议将整个基因组作为查询 FASTA 直接运行。
3. 建议使用**完整的连续基因序列**作为查询文件（例如采用 `fasta` 模式）。直接使用 mRNA 或 CDS 层级作为查询序列可能因剪接（Splicing）问题导致设计的 gRNA 序列在基因组中不存在，表现为完全匹配位点数量为 0 或未位于目标基因上。
4. 对注释文件：
   - 当前 `anno` 模式不是任意 GFF3 的通用解析器
   - `mrna/cds` 模式尤其依赖旧注释约定
5. 由于不同的基因注释文件中格式中不统一，建议提取出**基因序列**使用**fasta模式**。
6. `spacerscope-web` v1 无认证，不建议直接公网暴露。
7. `--progress-format jsonl` 主要用于 Web 壳和程序化调用，普通用户通常使用默认的 `text` 即可。
8. 选择最终的 gRNA 时，请确认所有完全匹配位点是否均位于**目标基因**上。
9. 在使用软件时，请给予软件足够的权限。

---

10. 常用命令速查

FASTA 模式

```
spacerscope fasta --query query.fa --ref genome.fa -o result.tsv
```

FASTA-CUT模式

```
spacerscope fasta-cut --query query.fa --ref genome.fa -o result.tsv --yes
```

ANNO 模式

```
spacerscope anno --annotation genes.gff3 --geneID gene:Gene1 --seq-type gene --ref genome.fa -o result.tsv
```

ANNO-CUT模式

```
spacerscope anno-cut --annotation genes.gff3 --geneID gene:Gene1 --seq-type cds --ref genome.fa -o result.tsv --yes
```

仅生成 HTML 报告

```
spacerscope --report-tsv result.tsv --html-output result.html
```

启动 Web 壳

```
spacerscope-web --bind 127.0.0.1 --port 8787
```